

Análise Crítica dos Modelos YOLO Custom, YOLO Default e CNN Criada do Zero

1. YOLOv5 Default (Pré-treinado)

Facilidade de uso/integração:

O modelo pré-treinado do YOLOv5 é extremamente fácil de usar. Não requer treinamento nem preparação do dataset. A integração com projetos no Google Colab ou Python local é direta e rápida. Ideal para prototipagem rápida.

Precisão do modelo:

Apesar de reconhecer a classe “bicicleta” com boa precisão (pois já está presente no dataset COCO), apresentou erros ao detectar “cadeiras”. O modelo confundiu cadeiras com outros objetos ou não conseguiu detectá-las, demonstrando sua limitação quando confrontado com objetos visuais que não estão bem representados no conjunto de dados original.

Tempo de treinamento/customização:

Inexistente. O modelo já vem treinado.

Tempo de inferência (predição):

Muito rápido. Adequado para aplicações em tempo real.

2. YOLOv5 Customizado (Treinado com as classes bicicleta e cadeira)

Facilidade de uso/integração:

Mais trabalhoso inicialmente, pois é necessário:

- Montar um dataset balanceado e anotado (Make Sense AI);
- Organizar as pastas de treino/validação/teste;
- Ajustar os arquivos de configuração (.yaml);
- Realizar o treinamento.

Após isso, a integração se torna tão simples quanto no modelo pré-treinado.

Precisão do modelo:

Excelente para as classes bicicleta e cadeira. O modelo customizado foi capaz de detectar corretamente ambas as classes, com alta confiança, mesmo em imagens de teste nunca vistas. Mostrou-se superior em tarefas específicas, adaptando-se perfeitamente ao domínio do projeto.

Tempo de treinamento/customização:

Moderado a alto, dependendo do número de imagens e da capacidade de hardware (GPU recomendada). No seu projeto, comparando 30 e 60 épocas, observou-se melhora na precisão com mais épocas, embora com maior tempo de treinamento.

Tempo de inferência:

Tão rápido quanto o modelo default.

3. CNN Criada do Zero para Classificação de Imagens (bicicleta vs cadeira)

Facilidade de uso/integração:

Exige que o usuário compreenda redes convolucionais e implemente a arquitetura manualmente. A classificação só funciona para imagens que contenham um único objeto, e não realiza detecção (bounding boxes).

Precisão do modelo:

Boa, desde que o dataset esteja balanceado e com qualidade. No entanto, por ser um modelo mais simples e não projetado para detecção, pode ter desempenho inferior ao YOLO customizado em termos de generalização e robustez.

Tempo de treinamento/customização:

Razoável. A construção da arquitetura e o treinamento são mais simples do que a adaptação do YOLO, mas exigem conhecimento técnico. Ideal para classificação binária simples como no caso de "bicicleta" vs "cadeira".

Tempo de inferência:

Rápido, especialmente se a rede for leve.

Conclusão Final

- **YOLOv5 Default** é rápido e prático, mas falha ao detectar com precisão objetos que não estão bem representados em seu dataset de origem, como a classe "cadeira" no seu projeto.
- **YOLOv5 Customizado** se mostrou a melhor opção em precisão e adaptação, acertando com confiança as classes "bicicleta" e "cadeira", após treinamento com

dataset específico.

- **CNN do Zero** é didaticamente importante e viável para tarefas de **classificação binária**, mas não substitui modelos de detecção como o YOLO quando se precisa de localização de objetos em imagens.